

1 Architecture globale du projet

Le projet est structuré en plusieurs modules permettant d'implémenter et d'analyser un système de Federated Learning dans différents contextes.

Dans un premier temps, une implémentation complète du Federated Learning est réalisée de manière manuelle afin de bien comprendre les mécanismes fondamentaux. Cette implémentation inclut l'entraînement local des clients, l'agrégation des modèles via Federated Averaging, ainsi que l'évaluation des performances.

Dans un second temps, plusieurs extensions sont ajoutées afin d'enrichir l'analyse et de se rapprocher de cas réels :

- Distribution non-IID des données pour simuler des environnements hétérogènes
- Utilisation de modèles plus avancés (CNN)
- Exploration de représentations latentes à l'aide d'autoencodeurs
- Intégration d'un framework industriel (Substra)
- Application à des données médicales issues de MIMIC-IV
- Visualisation des résultats à l'aide d'une interface interactive (Streamlit)

2 Organisation des sprints

2.1 Sprint 1 : Implémentation du Federated Learning

Le premier sprint est consacré à la mise en place d'une implémentation complète du Federated Learning dans un cadre simple.

- Implémentation d'un modèle de classification (MLP)
- Entraînement centralisé pour établir une baseline
- Simulation de plusieurs clients avec une distribution IID
- Implémentation de l'entraînement local des clients
- Implémentation de l'algorithme Federated Averaging
- Mise en place de la boucle de Federated Learning
- Comparaison des performances entre apprentissage centralisé et fédéré

2.2 Sprint 2 : Analyse et amélioration du modèle

Le second sprint vise à analyser le comportement du Federated Learning et à améliorer le modèle.

- Implémentation d'une distribution non-IID des données entre les clients
- Comparaison des performances entre IID et non-IID
- Étude de l'impact du nombre de clients sur la convergence
- Ajout de visualisations (courbes d'accuracy en fonction des rounds)
- Amélioration du modèle via l'utilisation d'une architecture CNN adaptée aux images

2.3 Rendu final : Extension et ouverture

Le rendu final consiste à enrichir le projet avec des extensions permettant de se rapprocher de cas d'usage réels.

- Intégration d'un autoencodeur pour l'apprentissage de représentations latentes
- Implémentation d'une version du Federated Learning avec Substra
- Application du modèle à un sous-ensemble de données médicales issues de MIMIC-IV
- Développement d'une interface interactive avec Streamlit pour visualiser les résultats et expérimenter les paramètres

3 Objectif global du projet

L'objectif de ce projet est de comprendre en profondeur le fonctionnement du Federated Learning, d'analyser ses performances dans différents contextes, et d'explorer son utilisation dans des scénarios réalistes, notamment dans le domaine médical.

Ce projet vise également à passer d'une approche académique à une approche plus proche des applications industrielles, en combinant implémentation, analyse et visualisation.